

Atelier Machine Learning

Analyse Comportementale Clientèle Retail

COMPTE RENDU

Atelier Pratique : E-commerce de Cadeaux

Préparé par Mohamed Amine Gharbi

Année Universitaire : 2025-2026

Table des matières

1	Introduction et Contexte du Projet	2
1.1	Objectifs	2
1.2	Architecture du Projet	2
2	Présentation du Jeu de Données	2
2.1	Statistiques générales	2
2.2	Principales Features Utilisées	2
3	Préparation et Nettoyage des Données	3
3.1	Problèmes de Qualité Détectés	3
3.2	Feature Engineering	3
3.3	Encodage des Variables Catégorielles	3
3.4	Normalisation	3
4	Réduction de Dimension — ACP	4
4.1	Objectif et Méthode	4
4.2	Résultats	4
5	Segmentation Client — K-Means	4
5.1	Sélection du Nombre de Clusters	4
5.2	Résultats du Clustering	5
6	Classification — Prédiction du Churn	5
6.1	Modèles Comparés	5
6.2	Résultats	6
6.3	Importance des Features	6
7	Régression — Prédiction du MonetaryTotal	7
7.1	Modèle et Configuration	7
7.2	Résultats	7
8	Déploiement — Interface Web Flask	7
8.1	Architecture de l'Application	7
8.2	Fonctionnalités Clés	8
8.3	Extrait du Code de Prédiction	8
9	Synthèse et Recommandations	8
9.1	Récapitulatif des Performances	8
9.2	Recommandations Métier	9
9.3	Limites et Perspectives	9

1 Introduction et Contexte du Projet

Ce projet s'inscrit dans le cadre du module **Machine Learning** (GI2-S1) et vise à réaliser une chaîne complète de traitement de données appliquée à l'analyse comportementale de clients dans un contexte e-commerce de cadeaux.

1.1 Objectifs

- Analyser et préparer un jeu de données réel de 52 features client
- Appliquer des techniques de clustering non supervisé (K-Means + ACP)
- Entraîner un classificateur de churn (départ client)
- Construire un régresseur de dépense totale (MonetaryTotal)
- Déployer les modèles via une interface web Flask

1.2 Architecture du Projet

Structure du projet

```
1 projet_ml_retail/  
2 |-- data/  
3 |   |-- raw/           # Donnees brutes originales  
4 |   |-- processed/     # Donnees nettoyees  
5 |   '-- train_test/    # Splits train/test  
6 |-- src/  
7 |   |-- preprocessing.py  
8 |   |-- train_model.py  
9 |   |-- predict.py  
10 |   '-- utils.py  
11 |-- models/           # Modeles sauvegardes (.joblib)  
12 |-- app/              # Application web Flask  
13 '-- reports/          # Visualisations et rapports
```

2 Présentation du Jeu de Données

Le dataset comprend **4 372 clients** décrits par **52 features** issues de transactions réelles et de données comportementales enrichies.

2.1 Statistiques générales

Caractéristique	Valeur
Nombre de clients	4 372
Nombre de features totales	52
Features numériques	34
Features catégorielles	9
Features engineered	9
Taux de churn réel	≈ 33%

2.2 Principales Features Utilisées

N°	Feature	Type	Description
1	Recency	Entier	Jours depuis dernier achat (0-400)

N°	Feature	Type	Description
2	Frequency	Entier	Nombre de commandes (1–50)
3	MonetaryTotal	Float	Dépense totale en £
4	MonetaryAvg	Float	Dépense moyenne par commande
5	CustomerTenure	Entier	Ancienneté client (jours)
6	ReturnRatio	Float	Taux de retour (0.0–1.0)
7	SupportTickets	Float	Nombre de tickets support
8	Satisfaction	Float	Note de satisfaction (/5)
9	Age	Float	Âge estimé (18–81 ans)
10	FavoriteSeason	Catég.	Saison d'achat préférée
11	Churn	Binaire	Indicateur de départ (cible)

3 Préparation et Nettoyage des Données

3.1 Problèmes de Qualité Détectés

Problème	Features Concernées	Traitement Appliqué
Valeurs manquantes	Age (30%), Satisfaction	Imputation par médiane / KNN
Valeurs aberrantes	SupportTickets (999), Satisfaction (-1)	Remplacement par NaN puis imputation
Formats inconsistants	RegistrationDate	Parsing <code>pd.to_datetime</code> + <code>dayfirst</code>
Feature inutile	NewsletterSubscribed	Suppression (variance nulle)
Données brutes	LastLoginIP	Extraction : IP privée/publique
Déséquilibre	AccountStatus, Churn	Stratification lors du split

3.2 Feature Engineering

Plusieurs nouvelles variables ont été créées pour enrichir la représentation :

```

1 # Ratio dépenses / recence
2 df['MonetaryPerDay'] = df['MonetaryTotal'] / (df['Recency'] + 1)
3
4 # Valeur moyenne du panier
5 df['AvgBasketValue'] = df['MonetaryTotal'] / df['Frequency']
6
7 # Ratio anciennete vs activite recente
8 df['TenureRatio'] = df['Recency'] / df['CustomerTenure']
9
10 # Extraction depuis RegistrationDate
11 df['RegYear'] = pd.to_datetime(df['RegistrationDate']).dt.year
12 df['RegMonth'] = pd.to_datetime(df['RegistrationDate']).dt.month

```

Listing 1 – Exemples de feature engineering

3.3 Encodage des Variables Catégorielles

- **Ordinal** : SpendingCategory, LoyaltyLevel, AgeCategory, ChurnRisk, BasketSize
- **One-Hot** : CustomerType, FavoriteSeason, Region, Gender, AccountStatus
- **Target Encoding** : Country (37+ modalités)

3.4 Normalisation

Après encodage et avant modélisation, un `StandardScaler` est appliqué sur les features numériques du jeu d'entraînement uniquement, puis transformé sur le test pour éviter tout data leakage.

4 Réduction de Dimension — ACP

4.1 Objectif et Méthode

L'Analyse en Composantes Principales (ACP) est appliquée pour réduire les 52+ features en un espace de dimension inférieure, utile pour la segmentation K-Means et la visualisation.

4.2 Résultats




FIGURE 1 – Courbe de variance expliquée cumulée et projection 2D des données

Interprétation de l'ACP

- **PC1** explique **20,8%** de la variance totale
- **PC2** explique **12,3%** de la variance totale
- Le seuil de **95%** de variance cumulée est atteint avec **≈15 composantes**
- La projection 2D révèle une distribution asymétrique avec des outliers distincts (clients VIP à forte dépense)

5 Segmentation Client — K-Means

5.1 Sélection du Nombre de Clusters




FIGURE 2 – Méthode Elbow et Score de Silhouette pour la sélection de k

Les deux critères convergent vers $k = 2$:

- La méthode Elbow présente un coude marqué à $k=2$
- Le score de Silhouette est maximal à $k=2$ (**0.311**)

5.2 Résultats du Clustering




FIGURE 3 – Projection 2D des 2 clusters K-Means (espace ACP)

Cluster	Taille (n)	Profil
Cluster 0	688	Clients VIP / gros acheteurs (outliers positifs)
Cluster 1	3 980	Clients standards / comportement moyen

Le cluster 0 regroupe les clients à dépense élevée, dispersés dans l'espace ACP, tandis que le cluster 1 forme un noyau dense autour de l'origine — comportement d'achat homogène.

6 Classification — Prédiction du Churn

6.1 Modèles Comparés

Deux algorithmes ont été entraînés et comparés via validation croisée et courbe ROC :

Modèle	AUC-ROC	Accuracy	Précision	Rappel
Random Forest	0.995	≈ 98.7%	Très élevée	Très élevé
Gradient Boosting	1.000	≈ 99.5%	Parfaite	Parfait




FIGURE 4 – Courbe ROC (gauche) et Matrice de confusion GradientBoosting (droite)

6.2 Résultats

Analyse de la Matrice de Confusion — GradientBoosting

- **Vrais Positifs (Churn correctement prédit) :** 288
- **Vrais Négatifs (Fidèles correctement identifiés) :** 578
- **Faux Positifs (Fidèles classés Churn) :** 6
- **Faux Négatifs (Churn non détectés) :** 3
- **Accuracy globale :** $(578 + 288) / (578 + 288 + 6 + 3) \approx 99.0\%$

Le modèle Gradient Boosting est sélectionné comme classificateur final.

6.3 Importance des Features




FIGURE 5 – Importance des variables — GradientBoosting (Gini)

Les trois features les plus discriminantes pour prédire le churn sont :

1. **FavoriteSeason** ($\approx 39\%$) — La saison préférée est fortement corrélée au départ
2. **CustomerTenureDays** ($\approx 38\%$) — L'ancienneté est le second prédicteur majeur
3. **FirstPurchaseDaysAgo** ($\approx 19\%$) — La date du premier achat complète le trio

7 Régression — Prédiction du MonetaryTotal

7.1 Modèle et Configuration

Un **Random Forest Regressor** est entraîné pour prédire la dépense totale du client (**MonetaryTotal** en £), avec les mêmes features que le classificateur (à l'exclusion de la cible et de Churn).

7.2 Résultats




FIGURE 6 – Réel vs Prédit (gauche) et Distribution des résidus (droite)

Métrique	Valeur
R^2 (coefficient de détermination)	0.927
MAE (Erreur absolue moyenne)	197.6 £

Interprétation

- Le modèle explique **92.7%** de la variance de la dépense totale
- L'erreur absolue moyenne de **197.6 £** est faible au regard de l'étendue des valeurs (jusqu'à 17 000 £)
- Les résidus sont très concentrés autour de 0, confirmant la qualité du modèle
- Quelques outliers (dépenses $> 10\,000$ £) génèrent des erreurs plus importantes — comportement attendu

8 Déploiement — Interface Web Flask

8.1 Architecture de l'Application

L'application Flask expose trois routes principales :

Route	Méthode	Fonctionnalité
/	GET	Formulaire de saisie client
/predict	POST	Prédiction Churn + Segment + Monetary
/dashboard	GET	Tableau de bord global (KPIs, distributions)
/test-models	GET	Tests des 5 modèles sur X_test

8.2 Fonctionnalités Clés

- **Prédiction unitaire** : saisie manuelle de 9 features (Recency, Frequency, etc.) → retour immédiat du niveau de risque churn, du segment K-Means et de la dépense prédite
- **Niveaux de risque** : Faible / Moyen / Élevé / Critique (basé sur la probabilité churn)
- **Dashboard** : KPIs globaux (taux de churn, distribution des segments) calculés sur X_test
- **Interface responsive** : design dark mode compatible mobile

8.3 Extrait du Code de Prédiction

```

1 def predict_single_client(features_dict):
2     X = pd.DataFrame([features_dict])
3     X = _encode_and_clean(X)
4
5     # --- Churn ---
6     clf = load_model("classifier_churn")
7     X_clf = _align_features(X.copy(), clf)
8     churn_proba = clf.predict_proba(X_clf)[0, 1]
9     risk = ("Faible" if churn_proba < 0.25 else
10            "Moyen" if churn_proba < 0.50 else
11            "Eleve" if churn_proba < 0.75 else "Critique")
12
13     # --- Segment ---
14     pca = load_model("pca")
15     kmeans = load_model("kmeans")
16     segment = int(kmeans.predict(pca.transform(X))[0])
17
18     return {"churn_probability": round(float(churn_proba), 4),
19           "risk_level": risk, "segment": segment}

```

Listing 2 – Fonction de prédiction client unique (predict.py)

9 Synthèse et Recommandations

9.1 Récapitulatif des Performances

Tâche ML	Modèle retenu	Performance
Clustering	K-Means (k=2)	Silhouette = 0.311
Classification Churn	Gradient Boosting	AUC = 1.000, Acc ≈ 99%
Régression Monetary	Random Forest	$R^2 = 0.927$, MAE = 197.6£

9.2 Recommandations Métier

1. **Cibler les clients à risque élevé/critique** : déclencher des campagnes de rétention personnalisées avant qu'ils ne partent
2. **Exploiter la variable FavoriteSeason** : adapter les offres promotionnelles à la saison préférée de chaque client
3. **Fidéliser les nouveaux clients** : CustomerTenure étant le deuxième prédicteur, les 90 premiers jours sont cruciaux
4. **Segmenter les communications** : le Cluster 0 (clients VIP) mérite un traitement premium distinct du Cluster 1

9.3 Limites et Perspectives

- La performance très élevée du Gradient Boosting (AUC=1.000) mérite une investigation du data leakage potentiel (notamment via ChurnRisk qui est une feature dérivée de Churn)
- Explorer des modèles de séries temporelles pour capturer l'évolution du comportement client
- Enrichir le dataset avec des données produits pour améliorer la segmentation

Conclusion

Ce projet a permis de mettre en œuvre une chaîne complète de Machine Learning allant de l'exploration des données brutes jusqu'au déploiement d'une application web. Les modèles obtenus présentent d'excellentes performances sur les trois tâches — clustering, classification et régression — avec une interface intuitive permettant une utilisation opérationnelle immédiate.